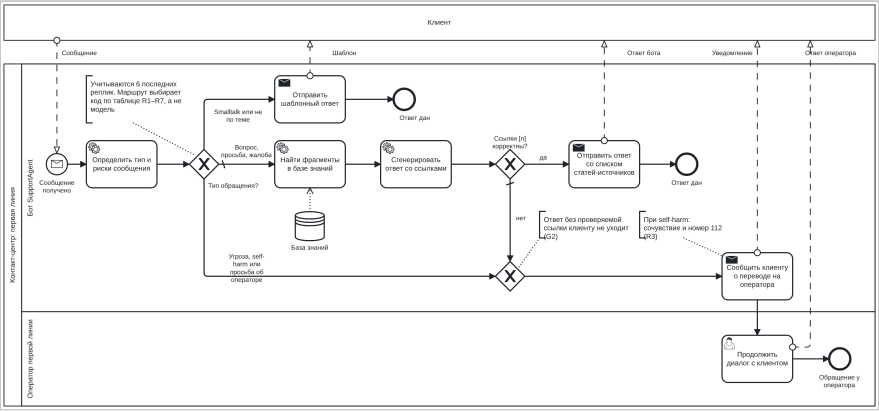
SupportAgent: бот первой линии поддержки связи

Проблема

Первая линия чат-поддержки тратит время на однотипные вопросы, ответы на которые уже есть в базе знаний. Наивный LLM-бот снимает нагрузку, но создаёт риски: выдумывает условия тарифов, отвечает шаблоном на угрозу или заявление о самоповреждении, не отдаёт человеку клиента, который об этом просит.

Решение

Бот сначала размечает сообщение: тип, угроза, просьба об операторе. Маршрут выбирает не модель, а таблица правил в коде. Опасные обращения и просьбы позвать человека сразу уходят оператору. Остальные получают ответ по базе знаний (~2 300 статей, только для частных клиентов) со ссылками на источники. Ответ без проверяемой ссылки клиенту не отправляется.



Результаты на синтетических наборах

Бизнес-риск	Результат
Пропустить угрозу или self-harm	0 пропусков из 12
Не перевести клиента, который просит человека	0 пропусков из 20
Неверно направить обращение	97% верных маршрутов (152/156), лишних переводов 0 из 32[1]
Условия для бизнеса или банка в ответе частному клиенту	0 ответов после фильтра сегмента (было 7 из 34)
Неверная информация в ответе	21% ответов содержат неподтверждённое утверждение; полностью верны 39%
Отказ, хотя ответ в базе есть	39% вопросов с ответом в базе

[1] Промпт триажа дорабатывался на этом же наборе, отложенной тестовой выборки пока нет.

Вывод: маршрутизация готова к теневому пилоту, генерация — нет. Поиск находит абзац с ответом в 91% вопросов, ошибки чужого сегмента устранены. Строгий промпт генерации сократил долю ответов с неподтверждёнными утверждениями с 41% до 21%, но поднял долю отказов там, где ответ был, с 14% до 39%: это компромисс, а не решённая задача.

Ключевое решение на основе данных

Раньше любая жалоба уходила оператору. Оценка показала, что граница «просьба / жалоба» размыта и классификатор ошибается на ней чаще всего (точность `intent` 73%), а каждая ошибка меняла маршрут. Жалобы стали сначала получать ответ по базе, эскалация осталась только по надёжным сигналам. **Точность маршрута выросла с 86% до 94%, лишних переводов стало 3% вместо 20% — без изменения модели;** после доработки промпта триажа — 97% и 0%. Цена решения записана как открытый риск: раздражённый клиент может получить инструкцию вместо человека.

План пилота

1. **Подготовка:** фильтр сегмента и короткие ответы сделаны. Осталось: эскалация угроз суда и повторных жалоб, ручная проверка LLM-судьи, выбор промпта генерации, интеграция с рабочим местом оператора.
2. **Теневой режим, 2–4 недели:** бот готовит черновик, оператор отправляет. Переход дальше — если не меньше 70% черновиков уходят без правок и нет пропусков угроз.
3. **Узкий контур:** бот отвечает сам в одной тематике. Меряем containment, CSAT и повторные обращения против операторов. По базовому сценарию бот высвобождает ≈117 часов оператора на 10 000 обращений.

Подробнее: бизнес-постановка · код и методика оценки

Автор: Евгений · hh.ru · Telegram · email · GitHub

Наборы синтетические, разметка — LLM-судья: цифры показывают поведение на трудных случаях, а не на реальном трафике. Проект учебный, не связан с ПАО «МТС»; база знаний — публичные статьи support.mts.ru.